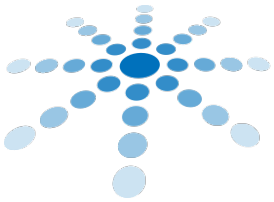

Hochschule Aalen

Hochschule Aalen

Fakultät Mechatronik

Autonomes Fahren

Marco Burkhardt

supervised by
Mr. Superhero Bauer

9. Mai 2021

Eidesstattliche Erklärung

Hiermit versichere ich, die vorliegende Abschlussarbeit selbstständig und nur unter Verwendung der von mir angegebenen Quellen und Hilfsmittel verfasst zu haben. Sowohl inhaltlich als auch wörtlich entnommene Inhalte wurden als solche kenntlich gemacht. Die Arbeit hat in dieser oder vergleichbarer Form noch keinem anderem Prüfungsgremium vorgelegen.

Datum: _____ Unterschrift: _____

Danksagungen

Weit hinten, hinter den Wortbergen, fern der Länder Vokalien und Konsonantien leben die Blindtexte. Abgeschieden wohnen Sie in Buchstabhausen an der Küste des Semantik, eines großen Sprachozeans. Ein kleines Bächlein namens Duden fließt durch ihren Ort und versorgt sie mit den nötigen Regelialien. Es ist ein paradiesmatisches Land, in dem einem gebratene Satzteile in den Mund fliegen. Nicht einmal von der allmächtigen Interpunktion werden die Blindtexte beherrscht – ein geradezu unorthographisches Leben. Eines Tages aber beschloß eine kleine Zeile Blindtext, ihr Name war Lorem Ipsum, hinaus zu gehen in die weite Grammatik. Der große Oxmox riet ihr davon ab, da.

Zusammenfassung / Abstract

Abstract
Das ist ein Abstract.

Zusammenfassung
Das ist das Haus vom Nikolaus und nebenan wohnt der Weihnachtsmann.

Inhaltsverzeichnis

Abbildungsverzeichnis

Tabellenverzeichnis

Abkürzungsverzeichnis

FPS Frames Per Second

GPU Graphic Process Unit

CPU Command Prozess Unit

NVCC NVidia Cuda Compiler

KI Künstliche Intelligenz

AI Artificial Intelligence

KNN Künstlich Neuronale Netze

CNN Convolutional Neural Network

CAN Control Area Network

1 Einführung Künstliche Intelligenz

Damit ein Fahrzeug autonom, d. h. ohne menschliches Zutun, im Straßenverkehr reagieren kann, muss es Fähig sein, die verschiedenen Verkehrsteilnehmer zu identifizieren. Hierbei wird sich einem Teilgebiet der angewandten Informatik bedient — der Künstliche Intelligenz (KI), auch Artificial Intelligence (AI) genannt.

In diesem Kapitel wird folgendes behandelt:

- Was ist Künstliche Intelligenz
- Modellbildung Neuronaler Netze
- Technische Umsetzung
- Uebersicht: Convolutional Neueral Networks (CNN)
- Bisheriger Stand im Projekt — Status Quo

1.1 Was ist Künstliche Intelligenz

Artificial Intelligence is the study of how to make computers do things at which, at the moment, people are better.[1]

KI ist eine Teildisziplin der angewandten Informatik, in der es um automatisierte Problemlösungen geht. Die Ursprünge lagen im Ansatz, allein Logik zu verwenden. Nachteil dabei: hohe Komplexität für Abdeckung aller Faelle. Es wurde als neuer Ansatz das menschliche Gehirn als Grundlage verwendet. Menschen reagieren auf eine sich verändernde Umwelt. Wir lernen aus Beispielen. Es erfolgt keine Abarbeitung von Schlussregeln wie "WENN ..., DANN ...". Man stelle sich das Halten des Gleichgewichts beim Fahrradfahren oder das Schreiben auf einem Blatt Papier vor. Die Reaktionszeiten für eine sequenzielle Abarbeitung wäre zu hoch. Beim Fahrradbeispiel wäre man schon längst vor der Abarbeitung aller Regeln umgeflogen. Das selbe gilt analog für den Fall des Schreibens, Bspw. eines Briefes. Es würde einfach viel zu lange dauern und die Regeln wären viel zu komplex.

Unser Gehirn funktioniert anders. Es passt sich den Situationen an und greift dabei auf Erfahrungen von schon erlebten Situationen zurueck. Das wollte man auch für Maschinen — dynamische Anpassung auf sich ändernde Randbedingungen. Das ist auch der Grund, warum künstliche Netze antrainiert werden muessen. Sie sollen auf Situationen reagieren und dabei auf 'Erfahrung von schon erlebten' zurueckgreifen. Das 'Schon Erlebte' stellt dabei das Trainingsmaterial dar, mit dem das Netzwerk antrainiert wird. Dennoch, im Allgemeinen ist zu entscheiden:

[1] [Bos20]

- Existiert ein Algorithmus, dann ist dieser vorzuziehen.
- Ist Erfahrung vorhanden, ein Problem anhand von Regeln zu beschreiben, ist dies vorzuziehen.
- Wenn die ersten beiden Ansätze nicht zum Erfolg führen oder nicht führten, dann kann der Einsatz von KI zielführend sein, wenn genügend Daten vorhanden sind, aus denen gelernt werden kann.

Im Straßenverkehr ändern sich zu jedem Zeitpunkt die Randbedingungen. Autos biegen ab, bremsen, ueberholen. Es gibt Verkehrsschilder, Ampelanlagen, Fussgaenger- und Fahrradwege und mehr. Menschen greifen im Straßenverkehr auf ihre Erfahrung zurueck. Möchte man als Ziel ansetzen, dass Fahrzeuge in der Lage sein sollen, im Verkehr ohne menschliches Zutun sich zu bewegen, ist eines ersichtlich. Die KI ist prädestiniert für den Einsatz im Bereich *autonomes Fahren*.

1.2 Künstlich Neuronales Netz

Künstlich Neuronale Netze (KNNs) versuchen das menschliche Gehirn nachzubilden. Wie unsere Nervenzellen trainierbar sind und Steuerungsaufgaben übernehmen, so möchte man auch, dass Computerprogramme ähnlich befähigt sein sollen, in analoger Weiße auf neue Situationen aus schon erlebten Beispielen zu reagieren. Man bedient sich hierbei dem Gehirn als biologischen Bauplan Abb. 1.1.

Die Dendriten nehmen das Signal auf, leiten es an den Zellkoerper weiter. Dort findet eine Gewichtung der Informationen statt. Die gewichtete Gesamtinformation geht ueber das Axon weiter und verteilt sich auf die Synapsen, welche jeweils mit weiteren Dendriten anderer Neuronen verbunden sind. Ein einzelnes Neuron wird in Form eines Softwarebausteins nachgebildet. Ein Neuron j besteht aus:

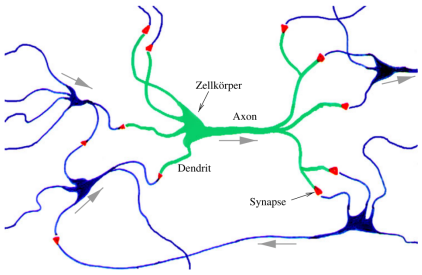

Abbildung 1.1: Menschliches Neuron; [Bos20]

- k gewichteten Eingaengen W_{kj}
- aus der Summe net_j der jeweils einzelnen Produkten der Gewichte W_{kj} und dem Wert des Eingangs O_k. net_j stellt damit die Information zusammen, die aus dem Netz in das Neuron eingehen.
- der Aktivitaet des Neurons, d. h. wie stark der potenzielle Einfluss von net_j auf andere Neuronen sein kann. Θ_j ist ein *Hyper Parameter*.
- der Ausgabe — Verbindung zu anderen Neuronen

Abb. 1.2 entspricht der Beschreibung.

Viele Neuronen sind so miteinander verbunden und bilden zusammen ein *Neuronales Netzwerk*. Als technische Modellierung existieren verschiedene Varianten, von denen aber hier nur die *forwaerts gerichtete* Variante interessiert.

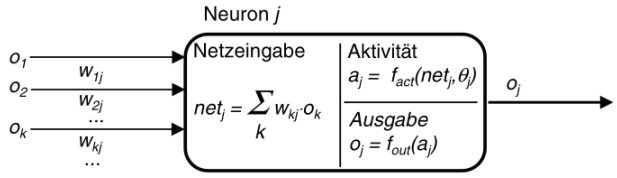

Abbildung 1.2: Modellierung eines einzelnen Neurons – Kuenstliches Neuron; [Bos20]

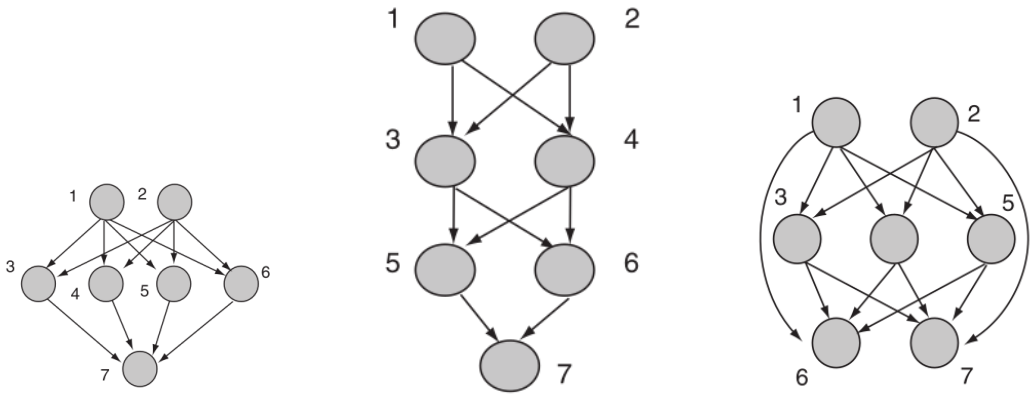

(a) (b) (c)

Abbildung 1.3: Fully Connected, Forward Looking Networks: a) Neuronen der Hidden Layer gehen in die Breite; b) Hidden Layer gleichbleibende Anzahl an Neuronen; c) Hintere Neuronen greifen direkt auf die unteren Schichten zu

Abb. 1.3 zeigt verschiedene Ausführungen eines *Feed Forward Neural Networks* oder auch *Fully Connected Neural Network*. Das entspricht der klassischen Vorstellung eines KNNs. Jedes Neuron ist mit jedem vorherigen und jedem nachfolgenden Neuron verbunden.

Die erste Schicht bildet den Eingang. Dort treffen Signale ein, z. B. in Form eines Bildes. Es geht weiter in die zweite Schicht. Tiefer liegende Schichten werden auch als *hidden layer* bezeichnet, da sie von außen, d. h. von den Schnittstellen, nicht zu sehen sind. Die letzte Schicht ist die Schnittstelle nach Aussen. Jedes Neuron gibt eine Wahrscheinlichkeit über den repräsentierenden *Classifier* aus. Zum Beispiel als Anwendungsfall in der Objekterkennung, ob Objekt von der Klasse ‘Afrikanischer Elefant‘ ist. Existieren mehrere Neuronen in der letzten Schicht, kann das Netz Aussagen ueber mehrere Classifier machen.

Es gibt noch wesentlich mehr Architekturen/Topologien, wie ein KNN aufgebaut sein kann. Jede hat ihre Vor- und Nachteile und somit eigene Anwendungsgebiete. In der Objekterkennung, Bildverarbeitung wird eine andere Variante als die *Fully Connected* Variante eingesetzt - das Convolutional Neural Network (CNN).

1.3 Uebersicht CNN

Im Gegensatz zum *Fully Connected Network* sind die Neuronen des CNNs nicht mit jedem Neuron der übergeordneten Schicht verbunden. Die Verbindung entsteht als Faltungsoperation mit einem Filter bestimmter Groesse (Kernel-Size). Der Filter ‘wandert‘ über das Bild

und verknüpft so jeden Bildbereich mit den darüber liegenden Neuronen. Jedes Neuron ist somit mit einem Filter verknuepft. Die Ergebnisse der Faltung entsprechen den Gewichten, mit denen das Neuron mit der darunter liegende Schicht verbunden ist. Allgemein gibt es mehrere Filter pro Schicht; dementsprechend besteht jede Schicht aus mehreren Neuronen. In Abb. 1.4 ist das Vorgehen aufskizziert.

Die Parameter der Filter haben anfangs zufaellige Werte. Die Werte werden im Trainingsprozess ‘gelernt‘ oder ‘antrainiert‘. Die Faltung, d. h. der Filter, wird nicht nur auf den Input (das Bild) , sondern auch zur Reduktion *Feature Extraction* der inneren Schichten *Hidden Layers* angewandt. Man kann fuer die inneren Schichten ein schon vor trainiertes, völlig beliebiges CNNs verwenden. Vorteil ist, es muss weniger Zeit für das Lernen seines Anwendungsgebietes aufgewendet werden und die *Feature Extraction* ist schon aufgebaut. Es gibt hierbei zwei wesentliche Punkte zu beachten:

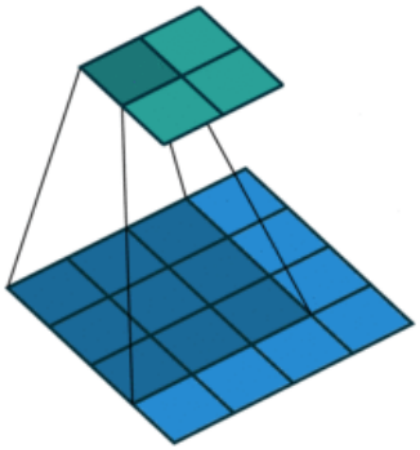

Abbildung 1.4: Jedes Neuron ist mit einer Faltungsoperation (Filter) mit dem darueber liegenden Neuron verbunden.

- Es muss ‘nur‘ der Eingang auf die korrekte Größe des Bildes angepasst werden.
- Die letzte Schicht muss ein *YOLO-Layer* sein mit den gewünschten Ausgangsneuronen für jede Klasse an zu detektierenden Objekten.

Die Vorgaengergruppe hat dieses Vorgehen angewandt und ein schon vortrainiertes Netzwerk als Grundlage verwendet. Vorteil: Lernprozess kostet weniger Zeit, weniger Trainingsmaterial wird benoetig, d. h. es kann mehr Energie / Zeit an die Anpassung des konkreten Anwendungsfalls aufgewand werden.

In Abb. 1.5 ist die Struktur des YOLO-Netzwerks aufskizziert. Im Unterschied zu den vorherigen Betrachtungen:

1. Die Hidden Layers bestehen intern jeweils wieder selbst aus einer Struktur speziell aufeinanderfolgenden Arten von Layern.
2. Die letzten Schichten muessen *fully connected* Yolo Layer sein.

Zu erstens:

- Faltungsschicht
- Normalisierungsschicht
- Aktivierungsschicht

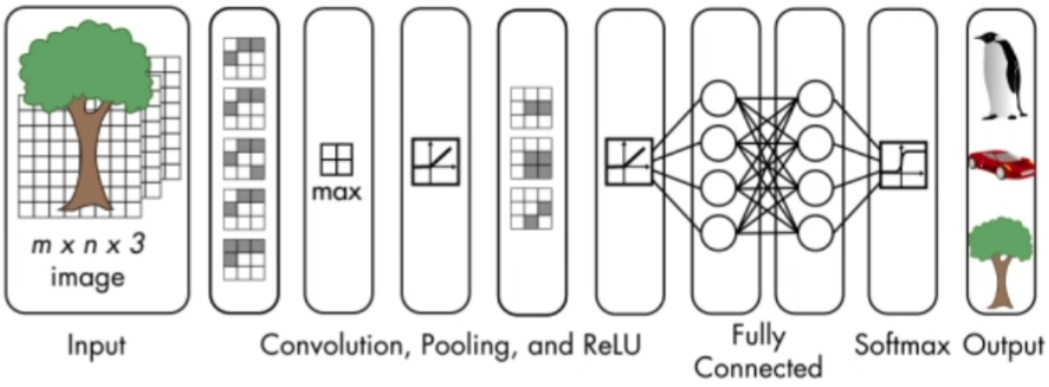

Abbildung 1.5: Links (hellblau) der Eingang (der Situation angepasst), in der Mitte (dunkelblau) das pretrained CNN Network, rechts (braun) das YOLO-Layer (auf Bedürfnisse angepasst)

Faltunsschicht ist fuer die Reduktion des Layergroesse zum einen und zum anderen fuer die Feature Extraction (nur die wichtigen Details sind fuer weitere Betrachtung wichtig) verantwortlich.

Normalisierungsschicht ist fuer die Beschleunigung des Trainingsprozesses verantwortlich.

Aktivierungsschicht entscheided darueber, ob ein Neuron "gezuendet" wird (geht in die aktuelle Berechnung ein) oder nicht.

Zu zweitens: Es gibt so viele Neuronen im *Fully Connected Layer*, wie es zu erkennende Objekte gibt. Hier im Projekt wird eine binaere Entscheidung getroffen — Auto da oder nicht da. Heisst, ein Neuron. Sollen aber mehrere Objekte erkannt werden, gibt es genau so viele *Fully Connected* Neuronen wie zu erkennende Objekte.

Die letzte Schicht *Softmax Layer* hat die Aufgabe, die Wahrscheinlichkeit, dass ein oder mehrere Objekte im Bild erkannt werden / worden sind, in ein Wahrscheinlichkeitswert wiederzugeben zwischen 0 und 1 — 0 fuer 0% und 1 fuer 100%.

Vorteil ein Framework zu verwenden — sei es Matlab wie hier im Projekt oder Python Implementationen wie PyTorch, Keras und mehr — ist, man braucht sich nicht expliziet um die konkrete Umsetzung der einzelnen Schichten kuemmern. Diese Arbeit nimmt das verwendete Netzwerk ab. Man kann darauf vertrauen, dass die internen Strukturen und Methoden so effizient wie moeglich implementiert wurden. Dennoch ist Wissen, wie mit dem Netzwerk umgegangen werden muss, Grundlagen, auf denen die Implementationen aufbauen, auch fuer den Anwender notwendig. Wie koennte man sonst abschaetzen, ob das berechnete Ergebniss plausibel ist oder nicht? Also ist man auch als Anwender eines Frameworks, wie es die Matlab IDE bereitstellt, nicht von Grundwissen befreit.

1.4 Bisheriger Stand im Projekt

Das Ergebniss von Vorgaengerarbeiten sind drei antrainierte Neuronale Netze. Die Netze arbeiten binaer — Erkennung von Auto erkannt / nicht erkannt. Sie besitzet zwei unter-

schiedliche *Tiefen*:

- 25 Hidden Layers
- 50 Hidden Layers

Vorgegriffen, in dieser Arbeit wird die Variante mit 25 Layers verwendet [BS20]. Es hat sich gezeigt, dass das flachere Netzwerk um ca. 900% bis 1000% schneller Objekte erkennt als das groessere Netzwerk. Auch die Kompilierungszeit ist um eine ganze Potenz schneller. Wie es in der Zuverlaessigkeit der Objekterkennung aussieht, bleibt offen. Da entschieden wurde, selbst wenn das groessere Netzwerk eine hoehere Zuverlaessigkeit besitzt, ist die Geschwindikeit im Betrieb nicht tragbar — teils geringer als ein Frame per Second. Genauer wird darauf im weiteren eigegangen.

2 Jetson Nano

In diesem Kapitel wird die Jetson Nano Hardware vorgestellt, weiterhin die Einrichtung der Hardware und die Ordenerstruktur — wo das Netzwerk und die Anwendungsprogramme liegen.

Es folgt:

- Uebersicht Jetson Nano
- Installation der noetigen Abhaengigkeiten
- Ordnerstruktur der Projektdateien

Die Hauptinformationsquelle seitens der Hardware ist Hersteller selbst [Nvi01a] und [Nvi01b].

2.1 Overview Jetson Nano

Einen Ueberblick der Hardware ist in Abb. 2.1 zu sehen. Der Jetson besteht aus einen Developement-Board — Eine Hardwareumgebung fuer die Entwicklung von Projekten — und einem Steckmodul. Das Steckmodul wird in die Steckleiste des Dev-Boards befestigt. Der Grafik- wie auch der Mikroporzessor sitzen auf dem Steckmodul. Somit kann nach Entwicklung und Testen das Steckmodul unmittelbar in das Produktivsystem integriert werden; sprich, es kann auf die Entwicklerplatine im Endprodukt verzichtet werden. Eine gute Einfuehrung ist auf dieser Internequelle zu sehen.

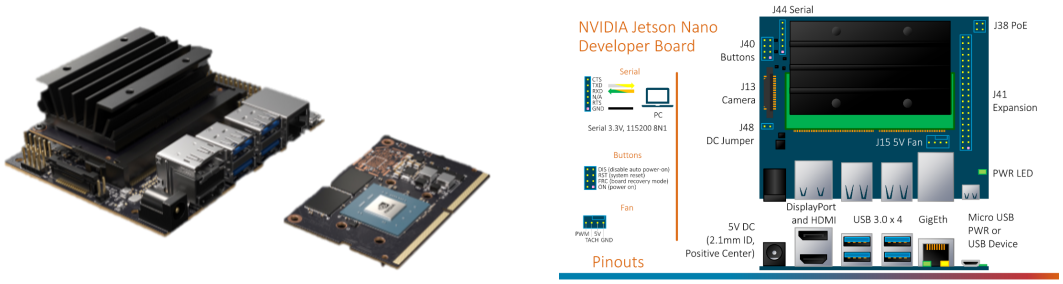

(a) (b)

Abbildung 2.1: Developement-Board mit Steckmodul (a) und Schema (b)

Abb. 2.2 zeigt, wie der Jetson Nano im Gesamtprojekt eingesetzt wird. Im System gibt es vier wesentliche Komponenten:

- Raspberry Pie — Zentrale Steuereinheit des Systems

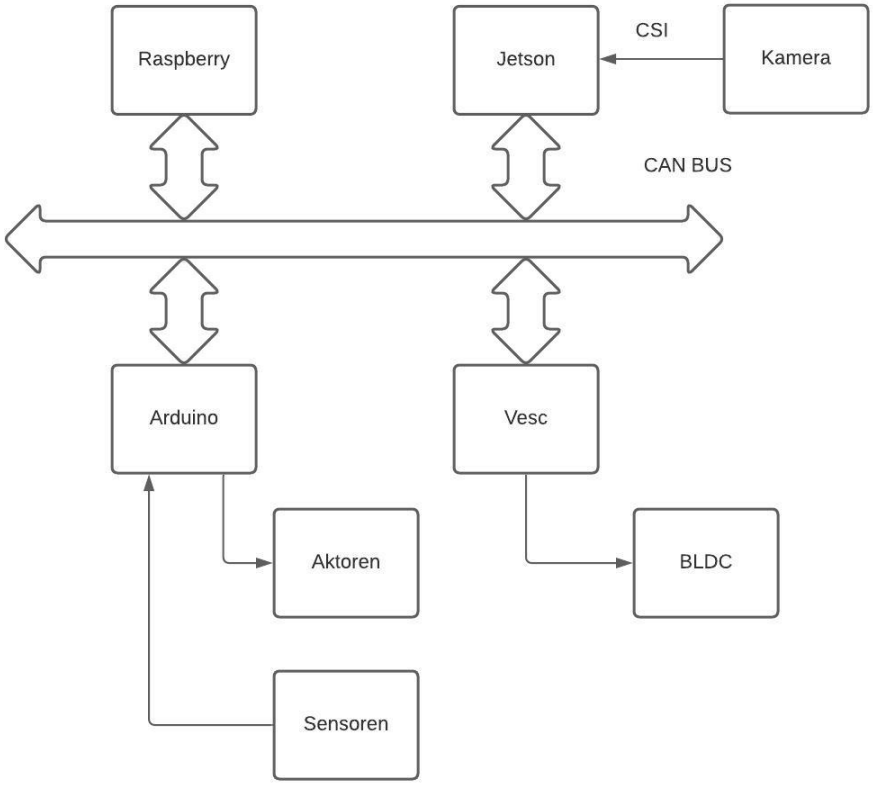

Abbildung 2.2: Alle Hardwarekomponenten des Systems

- Jetson Nano — Das “Auge” des Systems
- Arduino — Auswertung von Sensoren und Stellglied von Aktoren
- Vesc Motorcontroller — Stellglied fuer den BLDC Motor

Alle Hauptkomponenten sind mit dem *CAN*-Bussystem verbunden — siehe Abb. 2.2. Hierueber wird die Kommunikation abgewickelt. Der Jetson nimmt ueber ein Kameramodul Bilder der Umgebung auf. Intern werden die aufgenommen Bilder einem Neuronalen Netzwerk uebergeben, das das Bild auf interessierende Objekte untersucht. Hier sind die interessierenden Objekte Fahrzeuge. Und zwar nur Fahrzeuge als solches, heisst, es wird nicht weiter zwischen verschiedene Fahrzeugarten unterschieden. Die Objekterkennung ist somit binaerer Natur. Wurde ein Fahrzeug erkannt, wird eine Nachricht ueber das Bussystem verschickt. Es ist Aufgabe des Can-Protokolls, die Nachricht dem richtigen Adressaten zu uebergeben. Hier ist der richtige Adressat das Raspberry-Modul. Dort wird entschieden, was mit den eingehenden Informationen geschehen soll.

2.2 Software-Installation

Die Softwareinstallation wird detailiert auf der Nvidia Homepage beschrieben [Nvi01b]. Deswegen hier nur ein paar Punkte, die aufgefallen sind und zu erwaehnen sich lohnen:

- Jetpack
  - Aktuellste Installation auf SD Card Image
  - SD Card Image von *Getting Started with Jetson Nano* herunterladen
  - Gibt auch andere Quellen, aber dort nicht garantiert, dass *JetPack* und Abhaengigkeiten installiert werden
- SD Karte manchmal nicht lesbar gewesen
  - Staubeinschluss
  - Wie bei Nintendo 64 oder Gameboy
    - SD Karte entfehrnen und "pusten" hilft
- Starten im "Headless" Mode
  - benoetigt IP Adresse
  - mit Befehl `$ ipconfig` im Jetson zu bekommen

2.3 Ordner Struktur

Es existieren zwei Hauptordnerstrukturen:

- <Detector>
- <Hauptprogramm>

Beide liegen im Home-Verzeichnis des Users `</home/<user>/>`, wobei `<user>` in diesem Fall `jetson` ist.

<Detector>: Im der ersten Struktur liegt der von Matlab generierte Code und das Kompilat (Statische Library). Jedes mal, wenn der Anwender am Host PC in Matlab einen neuen Algorithmus definiert und uebersetzen laesst, diesen anschliessend auf das Zielsystem uebertraegt, finden sich die generierten Files und die kompilerte Datei in dieser Ordnerstruktur.
Matlab erstellt eine tiefe Struktur, heisst: sehr viele Unterorder und Verzweigungen. Aber saemtlicher Code und Kompilate finden sich dort.
Wichtig!!!: Auch wenn spaeter statische Library in anderes Programm — anderer Ausfuehrungsprozess — eingebunden wird, liegt das YoLo Netzwerk in dieser Struktur und ist somit eine **Abhaengikeit**. Die Ordnerstruktur darf **nicht** geloescht oder veraendert werden. Die statische Library verwenden absolute Pfade.

<Hauptprogramm>: Dort sind wiederum drei Haupt-Unter-Verzeichnisse angedacht:

- Detector
- Filter
- CAN_Dispatcher

Jeder dieser Unterverzeichnisse definiert ein seperates Programm, das jeweils einen eigenen Prozess startet.

Detector: Das ist ein in Cuda geschriebenes Programm, das die von Matlab generierte statische Library einbindet und autark auf der Zielhardware nach dem Kompilierungsvorgang (NVidia Cuda Compiler — NVCC) ausfuehrbar ist. Vorteil dieser Vorgehensweise:

- Host PC zum Starten des Algorithmus nicht mehr noetig
  - Statische Library in unabhaengiges Programm (spaeterer Prozess) eingebunden
- Anwendungsprogrammierer kann beliebige weitere Funktionalitaeten dem Programm hinzufuegen
  - Kommandozeilen Parser
  - Individuelle Ausgabe
    - Visuellen Modus
    - Ausgabe File Descriptor
    - Bit Stream
    - usw ...

Nachteilig zu erwaehnen ist: Programmierer sollte sich mit CUDA Syntax auskennen. Aber oft nicht so grosses Problem, da Schnittmenge mit C++ respektive C Syntax vorhanden. Dennoch ist erstrebenswert: so wenig wie moeglich in CUDA Code zu arbeiten. Deswegen Aufteilung in weitere Programme nach Motto: viele kleine Programme, die nur *eine* Aufgabe haben, aber diese gut und effizient umsetzen.

Makefile fuer den Kompaliervorgang im Projekt hinterlegt und kann mit `$ make` Befehl gestartet werden.

Filter: Die Uebertragung der Information (Objekt erkannt oder nicht) ist als Bit-Stream uber die Standartausgabe definiert. Da oben erwaehnt, ein Ziel ist, so wenig wie moeglich in CUDA zu Programmieren — sehr lange Compile-Time, sehr viel Abhaengikeiten, kompliziertes Make-File —, werden weitere Manipulationen in einem getrennten Programm umgesetzt *Filter*. Der Filter ist in C++ geschrieben und bereitet die Versendung der Informationen ueber CAN vor. Eine weitere Bearbeitung der Daten koennte wie folgt ausehen:

Es werden nur weitere Nachrichten an Busteilnehmer gesendet, wenn signifikante Aenderungen in der Objekterkennung vorliegen. Bspw. Objekt (Fahrzeug) wurde erkannt und Information ueber Bus gesendet. Es werden in der Sekunde mehrere Bilder aufgenommen und auf erkannte oder nicht erkannte Objekte ueberprueft. Es gibt jetz zwei Moeglichkeiten: Es kann immer eine Nachricht versendet werden, wenn Objekt erkannt — unter Umstaenden viele Nachrichten pro Sekunden ueber Bus — oder es wird eine Initialnachricht versendet: Signalisierung Objekt erstamlig erkannt und weitere nur, wenn sich bspw. Entfehrnung oder Naeherungsgeschwindigkeit signifikant aendern. Nachteil der ersten Moeglichkeit ist, dass Bus mit Nachriten “ueberschwemmt” wird, aber aus den vielen Nachrichten sich keine neue Erkenntnis generieren lassen. Diesen Nachteil wird in der zweiten Moeglichkeit versucht zu umgehen. Dort werden nur weitere Nachrichten versendet, wenn es wesentliche Aenderungen

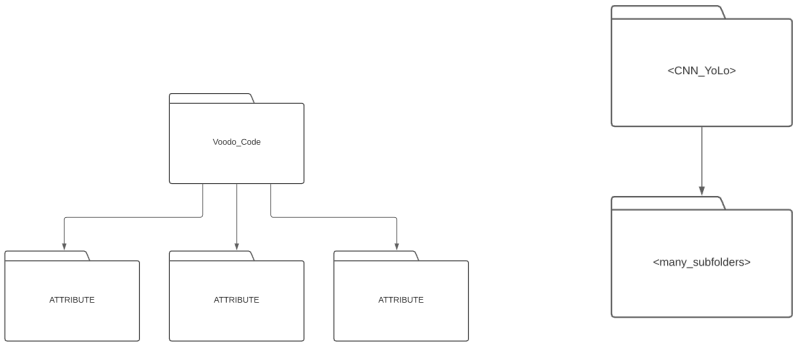

(a) (b)

Abbildung 2.3: (a) Voodo Code: Dort sind saemtlchen Prozesse definiert und werden von dort ausgefuehrt (Bash-Skript), (b) Yolo Netzwerk: Viele Unterverzeichnisse von Matlab generiert

gibt — hohe Naeherungsgeschwindigkeit von erkanntem Fahrzeug, usw. . . .

CAN_Dispatcher: Im Projekt wurde das *Hauptprogramm* und der *Filter* implementiert. Die entgueltige Kommunikation ueber CAN Bus blieb aus. Folgearbeiten konnen mit einer beliebigen anderen Sprache — bspw. Python, C, Rust, . . . — durchgefuehrt werden. Nvidia stellt bspw. ein Python Interface fuer die GPIO bereit. Es ist dementsprechend zu pruefen, ob ein Interface fuer SPI Controller existiert. Der Jetson hat kein eigenen CAN Controller, deswegen CAN Kommunikation nur ueber SPI moeglich.

Zusammengefasst

Die komplette Bearbeitung laeuft in drei getrennten Prozessen ab. Eine unidirektionale Kommunikation ist notwendig. Die Informationen von “tiefer” liegenden Prozessen muessen an den darueberliegenden Prozess weitergegeben werden. Erwaehnt wurde, dass als Ausgang ein Bit-Strom ueber Standart Ausgabe definiert wurde. Da auf dem Jetson ein Linux Betriebssystem ausgefuehrt wird, kann die Umsetzung der *Inter-Prozess-Kommunikation* dem Betriebssystem uebergeben werden. Als Mechanismus werden dafuer Pipes verwendet.

- `$ <Hauptprogramm> | <Filter> | <CAN_Dispatcher>`

Der senkrechte Balken signalisiert dem Betriebssystem, dass ein Kommunikationskanal von Prozess 1 zu Prozess 2 gebildet werden soll.

Die gesamte Ordnerstrukture ist wie folgt in Abb. 2.3 gezeigt umgesetzt.

3 Deployment / Installation

In der Objekterkennung hat sich der YOLO Algorithmus bewaehrt. Die YOLO Variante unterscheidet hauptsaechlich in den Letzten Schichten von anderen CNN Netzwerk Architekturen.

Es gibt mehrere Technologien, die den Aufbau eines Neuronalen Netzwerks unterstützen. Einige Bibliotheken in Python sind beispielsweise: PyTorch, Keras, Tensor Flow. Auch Matworks stellt ein eigenes Framework bereit. Vorteil von Matlab ist: Es gibt sehr viele speziell auf Matlab angepasste Tools für den kompletten Erstellungs-, Evaluierung- und Anwendungsprozesses. Hingegen die frei zugänglichen Alternativen wie in Python bieten einen kleineren Anwendungsbereich. Beispielweise, wenn für die Evaluierung im Bild die Objekte gekennzeichnet werden sollen, müssen andere Tool als z. B. nur Tensor Flow verwendet werden wie OpenCV zur Bildverarbeitung. OpenCV reichert das Bild mit Rahmen um erkannte Objekte an und setzt Labels. In Matlab ist alles dabei und weitere externen Tools sind unnoetig.

Im Projekt wird Matlab als Entwicklungsumgebung verwendet. Vorgängerarbeiten bauten darauf auf. Würde man sich gegen Matlab als Framework entscheiden, müsste der Erstellungsprozess von vorne begonnen werden.

Losgeloest von den verwendeten Werkzeugen, kann die Installation *engl. Deployment* abstrahiert werden, will heissen, der uebergeordnete Vorgang ist losgeloest von konkreten Technologien — zu sehen in Abb. 3.1.

In diesem Kapitel werden folgende Fragen beantwortet:

- Die Installation mittels Matlab. Es wird der konkrete Code — so wie er im Projekt angewendet wird — beschrieben.
- Zusammenfassung / Evaluierung

3.1 Installation

Der Vorgang, einen Matlab Algorithmus auf die Zielhardware zu übertragen und auszuführen, wird in drei Schritten abgearbeitet.

Schritt 1: Ein Algorithmus muss erstellt werden. Der Algorithmus hat die Form einer Routine (Funktion). Die Routine wird in der Matlab IDE erstellt. Der erstellte Code wird im Laufe des Vorgangs in Cuda Code umgewandelt und in der Zielhardware uebersetzt (kompiliert). Der Vorgang wird Cross-Kompilierung genannt.

Jetzt foglt die Beschreibung des Algorithmus. Er ist in der Matlab-Syntax verfasst. Die Beschreibung setzt sich wie folgt zusammen: erst Code, anschliessend Erlaeuterung.

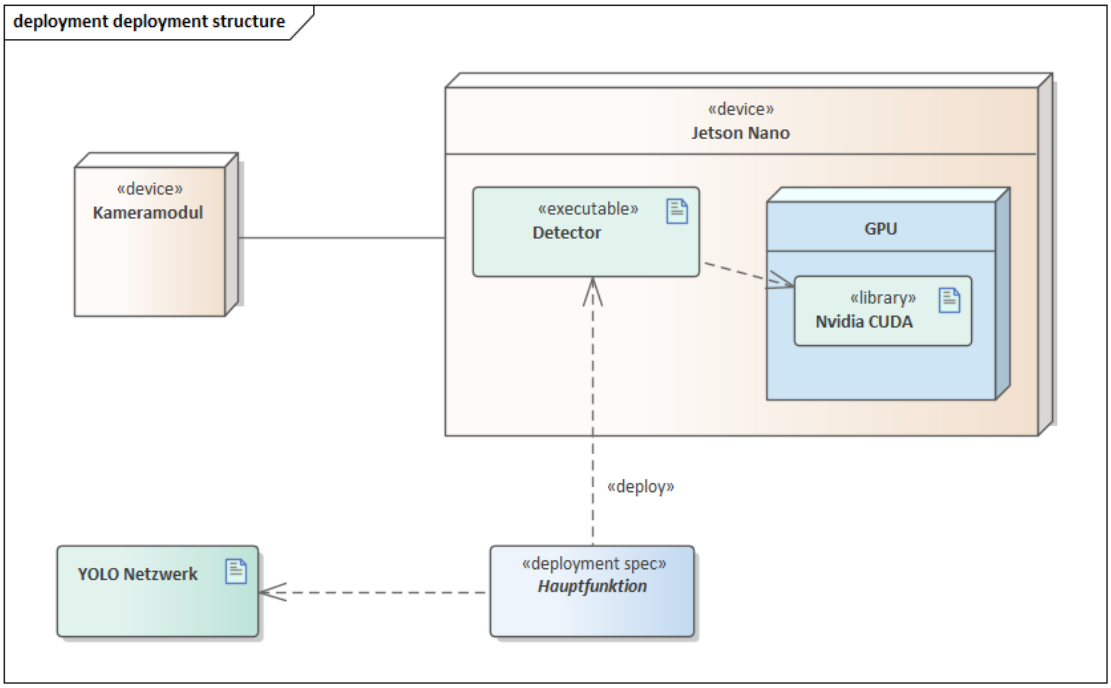

Abbildung 3.1: Die Hauptfunktion wird als Routine geschrieben. Sie verwendet als externe Abhaengigkeit das von der Vorgaengergruppe erstellte Neuronales Netzwerk. Der Host (f. i. Windows PC) uebertraegt Quelldateien auf die Zielhardware (JETSON NANO). Dort werden die Quelldateien uebersetzt und eine ausfuehrbare Datei *Binary* erstellt (hier: eine statische Library). Die Binary verwendet Nvidia CUDA Bibliotheken. Dort werden die aufwendigen Berechnungen der Objekerkennung ausgefuehrt. Die Objekterkennung verwendet ein Kameramodul.

```
function [x y width height score] = detectFunction()
%codegen
```

Es wird eine Fnktion deklariert, die fuenf Ausgabewerte liefert. Auch werden nicht alle Matlab-Interne Funktionen für die Konvertierung unterstützt. In der Funktion ist die `#codegen` Direktive zu empfehlen. Es wird dann eine Prüfung während der Erstellung des Algorithmus durchgeführt, ob Code gültig ist oder nicht.

```
persistant mynet
persistant hwobj
persistant cam

if isempty(mynet) || isempty(hwobj) || isempty(cam)
    hwobj = jetson
    cam   = camera(hwobj, 'vi_output, imx219 6-0010', [1280 720]);
    mynet = coder.loadDeepLearningNetwork('yoloNetwork.mat');
end
```

Die Variablen *mynet, hwobj, cam* sind mit dem Qualifier *persistant* versehen. In anlehnung an C hat das den selben Effekt wie eine *static* Deklaration. Der Code im if-Block wird nur im ersten Funktionsaufruf ausgefuehrt. Dort werden die Abhaengigkeiten initialisiert.

```
img = snapshot(cam);
img = imresize(imt, [224 224]);

[bboxes scores] = detect(mynet, img, 'Threshold', 0.5);
\% only the one with the highest score
[score_ index] = max(scores);
```

Es wird ein Bild eingefangen — PiCam — und dessen Greosse angepasst. Das verwendete Netzwerk hat 224 mal 224 mal 3 Eingangsneuronen. Der Faktor 3 steht fuer den RGB Farbaum. Jeder Farbraum wird intern vom Netwerk getrennt berechnet und am Ende der Pipline wieder zusammengefuehrt. Somit benoetigt ein Farbbild mehr Rechenleistung. Zukuenftig koennte geprueft werden, ob ein Netzwerk, das eine Graustufenabbildung verarbeitet erstens genau so zuverslaessig und zweitens schneller oder genauso schnell rechnet. *detect* ist eine Matlab-Interne Funktion. Ihr uebergibt man das KNN, das interessierende Bild und definiert einen Schwellwert, ab welchen Zuverlaessigkeitswert ein Objekt auch als das tatsaechliche Objekt angesehen werden kann oder nicht.

```
if ~isempty(bboxes)
   tmp_bbox = bboxes(idx,:);
   x = tmp_bbox(1);
   y = tmp_bbox(2);
   width  = tmp_bbox(3);
   height = tmp_bbox(4);
else
   \% nothing detected
   x = -1
   ...
   score = single(-1);
```

Wenn Objekt erkannt, wird darum ein Rahmen vom Netzwerk gezogen. Dementsprechen ist das bbox Objekt nicht leer. Darin sind die Koordinaten der Boudingbox gespeichert. Im ersten if-Teil werden die Koordinate ausgelesen und den Ausgangsparametern uebergeben. Wurde kein Objekt erkannt, ist die Boudingbox leer und es wird nach den Konventionen die Werte ausgefuellt (kein gueltiger Code — wie *errno* in C).

Schritt 2: Jetzt wird der in Schritt 1 erstellte Algorithmus auf die Zielhardware uebertragen— JETSON NANO. Dazu muss Verbindung vom Host zur Zielhardware aufgebaut werden. Matlab verwendet eine SSH Verbindung über TCP/IP. Die Verbindung wird über ein Hardware Objekt hergestellt.

- Target: <IP-Address>
- Login Name: *jestson*

- Passwort: *1111*

Für den Zugriff auf die Hardware des Jetsons muss eine IP-Adresse eingerichtet werden. Es kann entweder eine statische oder dynamische Adresse vergeben werden — seitens der Zielhardware, als JETSON NANO. Mit dem Befehl `$ ifconfig` kann die eigene IP-Adresse des Jetsons eingesehen und in der Matlab IDE eingegeben werden.

```
hwobj = jetson(<ip-address>, 'jetson', '1111');
```

Das Hardwareobjekt wird mit den Login Informationen der Zielhardware — JETSON NANO — ausgefuellt. Damit kann eine SSH Verbindung vom Host erstellt werden.

```
gpuEnvObj = coder.gpuEnvConfig('jetson');
gpuEnvConfig.BasicCodegen = 1;
...
results = coder.checkGpuInstall(gpuEnvObj);
```

coder ist eine statische Funktion bereitgestellt von Matlab. Sie erstellt ein Konfigurationsobjekt, das seinem Randbedingungen unterzogen wird. Jedes Projekt hat andere Randbedingungen. Demzufolge werden auch in unterschiedlichen Projekten unterschiedliche Optionen gesetzt. Zuletzt wird das Konfigurationsobjekt geladen und ueber die zuvor erstellte Verbindung Pruefungen auf der Zielhardware durchgefuehrt.

Ist die Pruefung erfolgreich durchgefuehrt — alle Abhaengigkeiten auf Zielhardware geladen und vorhanden —, kann der in Schritt eins erstellte Algorithmus in Code Zielcode umgewandelt werden. Dann erfolgt die Compilierung auf der Zielhardware.

Schritt 3: Der Matlab Coder generiert nun Code — nur von Funktionen, nicht von Skripten! Es sollte daher von Anfang an eine Funktion geschrieben werden, anstatt ein Skript zu erstellen und es hinterher in eine Funktion zu konvertieren.

Matlab exportiert den Quellcode auf den Jeton. Ist die Übertragung abgeschlossen, wird auf dem Jetson über den NVIDIA Cuda Compiler *nvcc* der von Matlab generierte Quellcode in eine ausführbare Datei kompiliert.

Zusammengefasst, noetige Schritte für eine Installation sind:

- YOLO Netzwerk bereitstellen
- Zielhardware konfigurieren
- Host konfigurieren
- Main-Funktion erstellen
- Code generieren
- Einbindung der Binary auf Zielhardware

YOLO Netzwerk: Es muss ein vorhandenes Netzwerk zur Erkennung von Objekten vorhanden sein. Getestet wird jeweils das von den Vorgängern erstellte und neue erstellte Netzwerk.

Zielhardware: Auf der Zielhardware müssen zusätzliche Bibliotheken installiert und Globale Systemvariablen exportiert werden. Benötigte Bibliothek ist die *Simple Direct Medial Layer v1.2* in der standart und developement Version. Der Cuda Pfad, in dem die Cuda Binaries und die Cuda Bibliotheken liegen, kann beispielsweise in der *.bashrc* hinterlegt werden.

Host: Die Codegenerierung — C++ und Cuda — sind von externen Tools abhaengig. Matlab benutzt die *Gnu Compiler Collection* und mehrere *Cuda Libraries* von Nvidia für die Erstellung der Binaries. In Linux ist der gcc standardmäßig in den Repos hinterlegt. Auf Windows Maschinen heißt das Compiler Paket MinGW. Die Abhängigkeiten seitens Nvidia müssen von deren Homepage heruntergeladen und installiert werden. Es werden Windos- und Linuxsysteme unterstützt.

Main-Funktion: Funktion, die in einer Endlosschleife Bilder von der Webcam aufnimmt und dem Detektor uebergibt. Der Detektor scannt das aufgenommene Bild nach Objekten. Wenn Objekte gefunden wurde, dann wird die entsprechende Bounding Box und Label auf das Bild gebunden und anschließend auf dem Bildschirm angezeigt. Hierbei muss entweder ein externer Monitor an den Jetson angeschlossen werden oder eine Remote- hergestellt werden.

Code Generation: Der Code wird in der Matlab Umgebung mit ein paar Codezeilen generiert. Das Kompilat kann auf mehreren Wegen auf den Jetson überspielt werden. Entweder über einem USB, via Ethernet Verbindung, etc. .... Man kann allgemein die Binaries in einem beliebigen Pfad installieren. Es muss nur darauf geachtete werden, dass die ausführbaren Dateien hinterher in den Pfad angefügt werden.

Zielhardware: Es ist nicht zwingend, eine ausführbare Datei zu erstellen. Eine weitere Möglichkeit ist, statische oder dynamische Bibliotheken zu generieren. Die Bibliotheken können dann in einem anderen Programm eingebunden werden. Der Vorteil, den Code fuer den Jetson direkt in Matlab als Executable zu generieren, ist, es müssen keine zusätzlichen Einstellungen getroffen werden.

3.2 Zusammenfassung

Es wurde ein Algorithmus fuer die Objekterkennung vorgestellt. Der Algorithmus verwendet das Kameramodul, um in Echtzeit die Umgebung aufzunehmen und auszuwerten. Der Algorithmus ist so geschrieben, dass er in der uebergeordneten Umgebung zyklisch aufgerufen und abgefragt werden kann *Polling*.

Es wurde weiterhin die Installation des Algorithmus ausgehend von Matlab auf das Zieldevice *JETSON NANO* gezeigt. Die Installationsroutine kann als Matlab Skript umgesetzt werden und ist auch so umgesetzt worden.

Der komplette Installationprozess ist graphisch in Abb. 3.2 nochmals aufgezeigt.

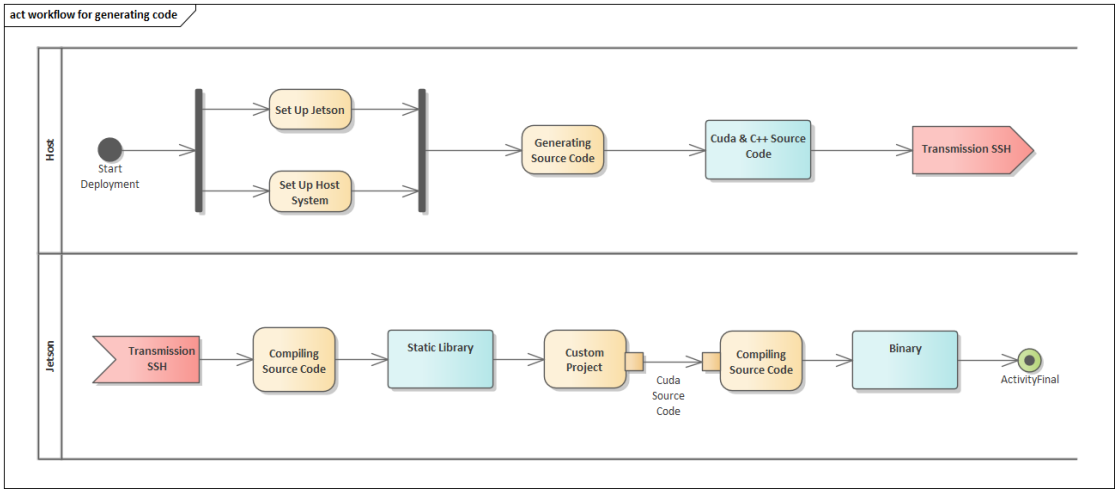

Abbildung 3.2: Die Zielhardware (Jetson) und der Host (f.i. WIN oder UNIX) muss eingerichtet werden. Die Reihenfolge der Einrichtung spielt keine Rolle. Der Quellcode wird im Host generiert und wird auf die Zielhardware uebertragen. Im Jetson wird eine static Library generiert. Die Library wird in ein eigenes Cuda Projekt eingebunden und hieraus ein ausfuehrbares Programm generiert.

4 Detektor & Filter

Bilder werden ueber ein Kameramodul aufgenommen, einem internen neuronalen Netzwerk uebergeben und auf erkannte Objekte (Fahrzeuge) ausgewertet. Sind Objekte — oder auch keine Objekte — erkannt worden, findet eine Informationsweitergabe statt. Die Ergebnisse des Neuronalen Netzwerks und seinem unterliegendem Algorithmus (YoLo) werden der Verarbeitungspipeline uebergeben.

Hintergedanken fuer diese Herangehensweisse:

- Weiterfuehrende Datenaufbereitungen sind somit von "Detektor" Prozess entkoppelt
  - Neue Algorithmen koennen sehr einfach durch andere Algorithmen der "Daten-Pipeline" ersetzt oder hinzugefuegt werden.
  - Abarbeitungsreihenfolgen der Algorithmen koennen beliebig neu angeordnet werden
  - Neue Algorithmen koennen in gewuenschter Sprache implementiert und der Pipeline hinzugefuegt werden
    - Somit keine Neukompilierung von eiem einzigen *monolitischen* Prozesses mit NVidia Cuda Compiler (NVCC) notwendig

Ein digitlaer Filter ist ein diskreter Algorithmus, eine Rechenvorschrift. Wenn hier von einem Filter gesprochen wird, ist ein Algorithmus in einem eigenen Ausfuehrungsprozess gemeint. Werden mehrere Filter hintereinander ausgefuhrt, findet eine Pipeline-Verarbeitung statt[1]. Es existiert ein unidirektionaler Kommunikationskanal zwischen den Prozessen, d. h. die Kommunikationsrichtung fliesst nur in eine Richtung.

Fragen, die hier behandelt werden, sind:

- Wie sind die Prozesse intern aufgebaut
- Wie sind deren Schnittstellen zur *Aussenwelt* definiert
- Welche Daten werden uebergeben

4.1 Detector

Die Architektur ist Stufenweise aufgebaut. In Abb. 4.1 ist zu sehen, Softwareteile hoeherer Ordnung sind weiter oben angeordnet und deren Abhaengigkeiten liegen tiefer und Verbindungslinien kennzeichnen die Abhaengigkeiten.

[1] https://www.elektronik-kompendium.de/sites/com/1705221.htm

Der oberste Block kennzeichnet den Hauptprozess. Die naechsten beiden Softwareblocke sind der *Command Line Parse* und die *Detect Funktion*. Der Command Line Parser wird beim ersten Prozessstart ausgefuehrt und liesst die in der Kommandozeile beim Starten des Prozess definierten Zusatzparameter und dekodiert diese, was die weitere Prozessabarbeitung beeinflusst. Bspw. wird der Prozess wie folgt:

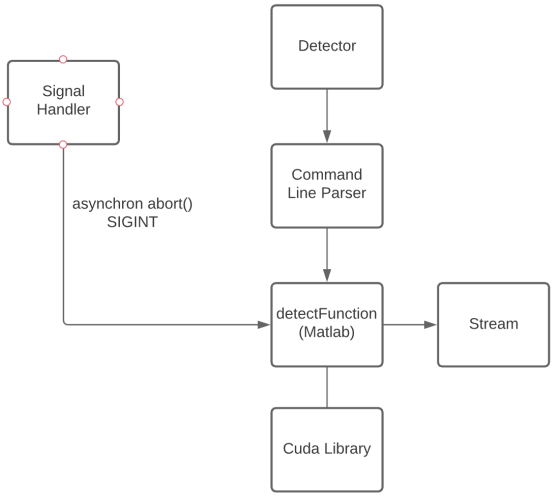

Abbildung 4.1: Softwareaufbau von Detector Hauptprozess

```
$ detector --visual-mode
```

gestartet, liesst der Parser das uebergebene Flag und die Ausgabe des Prozesses ist fuer den Anwender in lesbarer Form. Im *visual mode* ist aber eine Prozessausfuehrung innerhalb der Pipeline so nicht moeglich. Der ausgehende Prozess muss Schnittstellenkonform mit dem nachfolgenden Prozess der Pipeline sein, was *visual mode* nicht erfuellt. Somit kann der Prozess in *visual mode* nur getrennt gestartet und betrachtet werden (z.B. Zeitmessung, wie schnell *FPS* die Objekterkennung arbeitet).

Die *Detect Funktion* ist der in Matlab generierte CUDA Algorithmus fuer die Objekterkennung. Der Algorithmus wird in einer Endlosschleife zyklisch ausgefuehrt. Die direkten Abhaengikeiten des Algorithmus sind die CUDA Libraries. Vorteil von Matlab generierten Algorithmus ist: Softwareentwickler definiert den Algorithmus in Matlab-Code und Matlab produziert den CUDA Code, kompiliert ihn und erzeugt eine statische Library, die in ein unabhaengiges Projekt eingefuegt werden kann. Wie hier: Eingliederung CUDA Library in Detector Hauptprozess. Somit muss der Entwickler nicht direkt mit den CUDA Libraries arbeiten. Deren Aufrufe sind in der statischen Library *wegabstrahiert*. Ergebnis ist: Es kann weitgehend auf CUDA Code Syntax verzichtet werden und mit C++ respektive C Code Style gearbeitet werden, weil eine gemeinsame Schnittmenge mit CUDA Syntax vorhanden ist.

Der Hauptfunktionalitaet ist ein *Signal Handler* uebergeordnet. Der Signal Handler reagiert auf System Signale und fuer diese, wofuer er definiert wurde, unterbricht er den Hauptprozess und stellt sicher, dass die abhaengige Hardware wie Kamera Modul sicher gelschlossen wird. Bspw. mit dem asynchronen Befehl:

```
$ <CTR+C> [SIGINT]
```

wird der Prozess unterbrochen und die Hardware und diverse Filedeskriptoren geschlossen. Vor dem Signal Handler traten Probleme auf bei Testdurchlaeufen, in denen das Programm mehrmals unterbrochen wurde, dass die Hardware nicht mehr reagierte. Die Hauptfunktionalitaet uebergibt gewonnenen Daten dem *Output-Stream*.

Informationen werden mittels dem Betriebssystem bereitgestellten Pipelinesystem uebertragen. Die Schnittstellendefinition zum naechsten Prozess der Pipeline ist daher jeweil der

Outputstream. Dem uebergeordneten Verarbeitungsprozess (Filter) wird mit einem definierten Signal mitgeteilt, das ab diesem Zeitpunkt gueltige Daten am Stream anliegen. Ein Codeausschnitt ist:

```
// 1ter Prozess der Pipeline
std::out << some_random_data;
my::flag(std::cout, 0xBADEAFFE);
std::out << valid_data;

////////////////////////////////

// 2ter Prozess der Pipeline
do_some_random_stuff();
wait(my::flag(std::cin, 0xBADEAFFE));
do_important_stuff();
```

Bash Skript starte bspw. beide Prozesse in einer Pipelinestruktur:

```
$ Detector | Filter1
```

Gibt *Detector* Daten vor dem Flag *0xBADEAFFE* aus, werden diese von *Filter1* nicht weiter bearbeitet. Erst wenn das Flag gelesen wurde, werden die nachfolgenden Daten des Streams als gueltige Daten betrachtet und gehen in die Bearbeitung mit ein.

Bleibt nur noch zu klaeren, welche Daten der *Detector* Prozess der Pipeline uebergibt.

Datenstruktur

Das unterliegende Neuronale Netzwerk hat eine Eingangsgroesse von:

$$[224\ 224\ 3].$$

Die *3* ist die Tiefe — RGB Farbraum. Das Kameramodul nimmt Bilder in *720p* Aufloesung auf. Die Bilder muessen anschliessend heruntergerechnet werden und werden dann dem Neuronalen Netzwerk uebergeben. Um erkannte Objekte (Fahrzuege) werden *Bounding-Boxes* (Begrenzungskaesten) gezogen. Sie signalisieren, wo im Bild das erkannt Objekt liegt. Kleinere Bounding-Boxes bedeuten, dass das erkannt Objekt weiter entfehrnt ist, wobei groessere weiter weg bedueten. Sie koennen weiterhin weiter links in der Aufnahme liegen oder weiter rechts, sowie nach unten oder oben versetzt. Somit besitzen Bounding-Boxes mehrere Attribute:

- Position
  - X-Kord
  - Y-Kord
  - Height

  - Widht

- Konfidenz-Score

Das Positions-Attribute bezieht sich auf die linke obere Ecke der Bounding-Box relativ zur linken oberen Ecke der Aufnahme. Die Y-Koordinate wird nach unten abgetragen (Abb. 4.2). Der Konfidenz-Score gibt an, wie "sicher" sich das Netzwerk ist, ob das erkannte Objekt tatsaechlich ein Fahrzeug ist oder nicht. Der Konfidenz-Wert kann in spaetere Algorithmen verwendet werden. Wird kein Objekt in einer Aufnahme erkannt, nimmt der Konfidenz-Score einen Wert von -1 an.

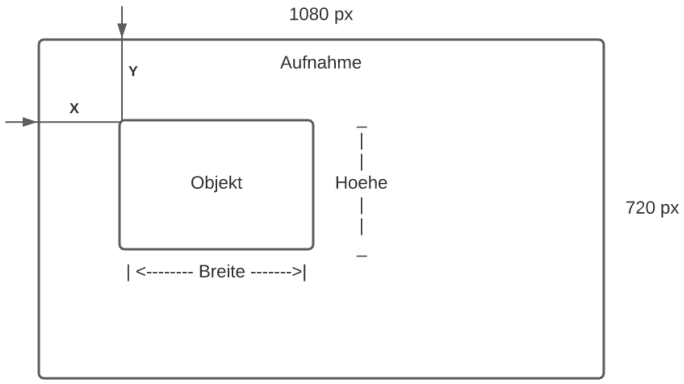

Abbildung 4.2: Aufnahme + Objekterkennung. Attribute: X, Y, Hohe, Breite

Daten, die ueber den Stream in die Pipelineverarbeitung miteingehen, sind:

- X-Kord
- Y-Kord
- Height
- Width
- Score

Wie oben beschrieben, ist eine Aufnahmen maximal $224 \cdot 224$ Bildpunkte tief. Somit gilt:

$$M := \{X, Y, Height, Width\}$$
$$\{x \in M \mid x \leq 224\}.$$

Das heisst, die benoetigte Breite betraegt:

$$Bitbreite = \lceil ld(224) \rceil.$$

Der Score liegt zwischen: $0 \leq Score \leq 100$ und $Score < x \in M$. Zusammengefasst: Jedem Wert genuegt eine Bitbreite von mindestens 8 Bit. Die gesamte Datenbreite ist: $5 \cdot 8Bit = 40Bit$. Die Reihenfolge der Daten wird wie folgt ausgegeben:

$$[X\ Y\ Height\ Width\ Score].$$

Wird kein Objekt (Fahrzeug) erkannt, wird eine Null-Folge versendet. Plausibilitaet: In einer Nullfolge ist jedes Bit 0. Somit auch die Hoehe und Breite 0. Eine Bounding-Box mit Hoehe und Breite 0 ist nicht vorhanden. Daraus folgt: Eine Nullfolge kennzeichnet "kein Objekt erkannt".

Temperatur & Verarbeitungsgeschwindigkeit

Die Verarbeitungsgeschwindigkeit wird allgemein von der Hardware begrenzt. Im Speziellen hier von der Graphic Process Unit (GPU). Die GPU ist aus Halbleiterstrukturen gefertiegt. Es gilt: Je waermer das Bauteil wird, desto groesser die Leitfaehigkeit der inneren Schalter, desto groesser die Verlustleistungen und das resultiert wiederum in mehr produzierte Abwaerme, was wiederum zum Anfang der Argumentationskette fuehrt. Eine Konsequenz daraus ist, dass die Waerme abgefuehrt werden muss. Wird sie nicht in einem ausreichenden Masse abgefuehrt, drosselt sich die GPU. Im gedrosselten Zustand produziert sie weniger Abwaerme. Die GPU drosselt sich soweit herunter, bis sich ein Gleichgewicht einstellt zwischen produzierter und abgefuehrter Waerme.

Der Jetson Nano hat von Werk aus ein Passiv-Kuehlsystem — siehe Abb. 2.1. Betriebsarten des Jetson sind:

- X Server
- Terminal

Der X-Server startet beim Hochfahren des Betriebssystem die graphische Oberflaeche — wie normaler Betrieb in bspw. Windows 10. Wurde in dieser Betriebsart der Objekterkennungsprozess angestossen, kam nach wenigen Augenblicken eine Mitteilung, dass die Temperatur unzulaessig hoch sei und deshalb die GPU gedrosselt werde. Diese Meldung wird nicht im Terminal Mode angezeigt, expliziet nur im X Server Betrieb.

Als Gegenmassnahme ist eine Aktiv-Kuehlung verbaut worden. Eine Besonderheit ist: Die Aktiv-Kuehlung muss vom Anwender "angestossen" werden. Befehle sind aus [bgu] entnommen. Die wichtigsten sind:

- `$ sudo /usr/bin/jetson_clocks`
  - Setzt CPU, GPU auf FULL POWAH
- `$ sudo sh -c 'echo 255 > /sys/devices/pwm-fan/target_pwm'`
  - Aktiviert Fan
- `$ sudo sh -c 'echo 0 > /ysy/devices/pwm-fan/target_pwm'`
  - Deaktiviert Fan

Die Ausfuehrungsgeschwindigkeit mit der Passiv-Kuehlung betrug im Schnitt ca. 8–9 Frames Per Second (FPS). Mit Aktiv-Kuehlung lagen die Werte auf ca. 8–9.5 FPS.

	Passiv Kuehlung	Aktiev Kuehlung
[FPS]	8–9	8–9.5

Tabelle 4.1: Messung: Aktiv-/ vs. Passivkuehlung; Zeitintervall: 60s

In Tabelle 4.1 sind beide Kuehlarten gegenuebergestellt. Die Messungen wurden jeweils in einem Zeitintervall von 60 Sekunden und dem selben Bild durchgefuehrt. Es ist somit zweifelhaft, ob die Aktivkuehlung einen Mehrwert bietet. Wenn es gegen den erhoeten Energiebedart des Luefters gegengerechnet wird, ist die Passivkuehlung die bessere Wahl.

Achtung!!!
Es hat sich herausgestellt, sobal Luefter aktiviert wurde, “fror” das System nach kurzer Zeit ein. Aktueller Stand: Auf aktive Kuehlung verzichten. Aber Nachteil verbleibt: Mehldung, wenn Objekterkennung aktiv, dass Command Prozess Unit (CPU) und GPU heruntertaktet.

4.2 Filter 1 — Transition

Dieser Prozess hat die Aufgabe, die empfangenen Inofrmationen des Detectors zu verarbeiten. Die Grundidee ist, nicht jede Empfangene Nachricht vom Detector unbehandlet durchzulassen. Erst wenn signifikante Aenderungen auftreten, soll dem uebergeordneten Prozess (bspw. dem Prozess, verantwortlich fuer die CAN-Uebertragung) eine Mitteilung gemacht werden.

Das System soll mit Zustaenden modelliert werden. Drei Zustaende sind definiert: *Warten*, *Objekt* und *Velocity*. Der Wartezustand wird gleich nach dem Prozessstart eingenommen. Dort wird so lange verharrt, bis ein Objekt erkannt wurde. Ist ein Objekt erkannt worden, soll eine Message ausgegeben werden. Allgemein gilt: Alle Messages, die der gesamte Prozess erzeugt, werden der Verarbeitungspipeline uebergeben.
Jetzt befindet man sich im *Objekt-State*. Jetzt soll es wiederum Bedingungen geben, in denen Aktionen definiert sind. Alle Aktionen beziehen sich impliziet auf das erkannte Objekt.

Objekt-State:

- Objektdistanz $> X_{Tresh}$ — No Message
  - Erkanntes Objekt liegt ueber dem Grenzwert X_{Tresh}, d. h. Objekt ist nich zu nah, sondern weit “genug” entfehrnt. In diesem Fall muss nur noch die Positionsaenderung bezogen auf die Zeit untersucht werden. Diese wird im *Velocity-State* durchgefuehrt $\Rightarrow$ Uebergang in naechsten State.
- Objektdistanz $\leq X_{Tresh}$ — Message
  - Erkanntes Objekt unterschreitet kritischen Wert $\Rightarrow$ Objekt zu nah.

Nur wenn das erkannte Objekt weit genung entfehrnt ist, wird in den naechsten State (*Velocity-State*) gewaechselt, in dem die Positionsaenderung bezogen auf die Zeit untersucht wird. Aendert sich die Position zu schnell, wird eine Message ausgegeben. Liegt die Positionsaenderung unter einem kritischen Wert, wird auf die Message verzichtet. Aber in beiden

Faellen wird wieder nach der Untersuchung in den *Objekt-State* zurueckgegangen.

Velocity-State:

- Objekt-Position aendert sich nicht signifikant: $\frac{\partial x}{\partial t} + \frac{\partial y}{\partial t} \leq V_{Tresh}$ — Keine Message
- Objekt-Position aender sich signifikant: $\frac{\partial x}{\partial t} + \frac{\partial y}{\partial t} > V_{Tresh}$ — Message

Das beschriebene Vorgehen ist in Abb. 4.3 zu sehen.

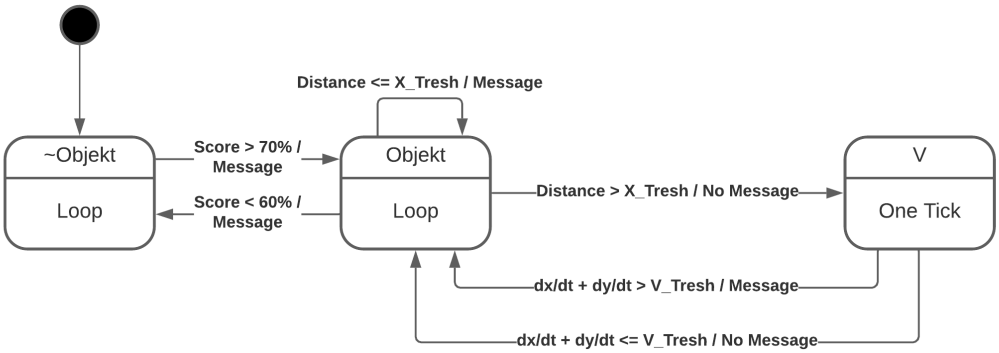

Abbildung 4.3: Filterung Objekt Erkennung: Filter1 — Transmission

Wenn vom *Wait-State* in den *Objekt-State* gewechselt wird, ist die Bedingung: Confidence Score $\geq 70\%$ erfuellt. Das soll *Jittering* verhindern. Als *Jitter* wird eine Signalschwankung bezeichnet. Ein haeufiges "Hin- und Herpendeln" des Signal am Grenzwert verursacht ein genauso haeufiges "Hin- und Herpendeln" der Wirkung. In der Hardware wird hierfuer ein *Schmitt-Trigger* verwendet, der diesen of unerwuenschten Effekt verhindert. Hier hat es folgenden Hintergrund: Der Detector generiert ein Signal, wenn die Confidence $\geq 50\%$ ist. Wird nun bei 50% direkt in die Objekt-Erkennung gewechselt, und im darauffolgenden Messvorgang des Detectors (zur Erinnerung: ca. 10 FPS) wird das Objekt nicht mehr erkannt[2], wird die nachfolgende Pipeline mit Nachrichten der Art: Objekt erkannt, Objekt verschwunden — ueberschwemmt.

CAN Dispatcher

Der CAN Dispatcher ist das letzte Glied der Verarbeitungspipeline. Es ist logisch, da im Endeffekt eine Informationsweitergabe ueber den CAN Bus angedacht ist. Der Empfaender

[2]Entweder weil einfach gesehen das Objekt verschwunden ist (guter Fall) oder weil das Objekt an der Grenze ist, ob als Objekt erkannt oder nicht. Es kommt auch vor, dass sich das Netzwerk taeuscht. Bspw. eine Orange ist kein Fahrzeug, kann aber unter besonderen Bedingungen als solches gehalten werden. In diesem Fall waere aber ein niedriger Confidence Score wuenschenswert. Gegenmassnahmen waeren bswp. Netzwerk mit erweiterten Datensaetzen trainieren

der CAN Nachricht ist im Projekt der Rasperry Pi. Dort findet die uebergeordnete Informationsbearbeitung statt.

Die Aufgabe des CAN Dispatchers ist es nun, eine CAN Nachriht zu versenden. Dieser Prozess wurde noch **nicht** implementiert. Im naechsten Kapitel wird zusammengefasst, warum und welche Arbeiten hierfuer noch noetig sind.

Punkte, die fuer die Aufteilung eines seperaten getrennten Prozesses fuer die Versendung sind:

- Versendung Informationenn ueber CAN komplett entkoppelt von anderen Prozessen/Aufgaben der Verarbeitungspipeline
- Der Algorithmus kann in einer beliebigen Sprache geschrieben werden (da komplett von anderen Prozessen entkoppelt)
- Von NVIDIA geschriebene Skripte bspw. in Python koennen somit problemlos verwendet werden, wenn sich fuer Python als Sprache entschieden wird

Das was zu beachten ist: Der erstellte Prozess muss in das Bash-Skript noch eingefuegt werden.

Bash Skript — Pipeline

Sind alle gewuenschten Prozesse definiert und bereitgestellt worden, koennen sie in die Verarbeitungspipeline hinzugefuegt werden. Dafuer ist ein Bash-Skript angelegt/vorgesehen worden folgender Form:

```
#!bin/bash
## Definition Signal Handler
Detector | Transition | ... | CAN_Dispatcher
```

Es kann gesehen werden, dass weitere Prozesse in die Pipeline hinzugefuegt werden weiter koennen. Bei aller Flexibilitaet, was diese Herangehensweisse bereitstellt, gibt es dennoch ein evtl. Nachteil. Ob dieser fuer die Problemstellung als gross angesehen werden kann, entscheidet der konkret vorliegende Fall.

Da alle Prozesse der Reihe nach ausgefuehrt werden, entsteht so eine Totzeit. Die Totzeit ist abhaengig von der Rechengeschwindigkeit, mit der der Prozessor taktet. Ist die Totzeit im Verhaeltniss gegenuber der im System groessten Zeitkonstante klein, dann diese vernachlaessigt werden. Hier ist die groesste Zeitkonstante die Verarbeitungsgeschwindigkeit der Objekterkennung (ca. 10 FPS). Der Prozessor Taktet mit mehreren *GHz* Takt[3]. Wenn sehr grosszuegig geschaetzt wird, kann mit einem Mindesttakt von grob 1 GHz gerechnet werden. Der Kehrwert ist die Verstrichene Zeit pro Rechenoperation. Da verbauter Prozessor ARM Prozessor ist und dieser wiederrum RISC Architektur verwendet, kann mit einer schnelle Befehlsabarbeitung von ca. 1 Assembler Befehl pro Takt (Ziel von RISC Architektur) gerechnet werden. Jetzt kommt es an, wie viel Code den Prozessen zu Grunde liegt und schlussendlich, wie viele Prozesse in der Pipeline definiert sind.

[3]Variable Frequenz. Siehe Datenbaltt. Grundtakt ca. 1.8 GHz

Ein Nachteil einer Hochsprache wie C oder C++ ist, dass man nicht so einfach die Assembler Befehle zaehlen kann, die der Compiler produziert (starke Optimierung ⇒ fuer Menschen sehr schwer lesbarer Code). Aber wenn im "Hauptabarbeitungspfad" — d. h. dort, wo hauptsaechlich die Rechenzeit aufgewendet wird — effizient programmiert wird, kann davon ausgegangen werden, dass der Prozessor im Vergleich zu den $\frac{1}{10}s$ (benoetigte Zeit Objekterkennung) den Verarbeitungsprozess nicht allzu stark beeinflusst.

Fazit:

- Code Komplexitaet so gering wie moeglich, aber so viel wie noetig halten. Vor allem in den Pfaden, in denen angenommen werden kann, dass dort ein Grossteil der Rechenzeit aufgewendet wird.
- Anologe Ueberlegung auch auf die Verarbeitungspipeline: So wenig wie moeglich, aber so viel wie noetig

5 Fazit

Es wird ein Ueberblick ueber die CAN Versendung gegeben. Danach wird ein kurzer Rueckblick gegeben, was im Projekt umgesetzt wurde. Am Ende werden die Punkte angesprochen, die noch offen sind oder im Laufe der Arbeit aufgefallen sind.

5.1 CAN Transmission

In einem CAN Netzwerk teilen sich die einzelnen Teilnehmer den gesamten Bus — Abb. 5.1 (a). Ein Teilnehmer wird als CAN-Node bezeichnet.

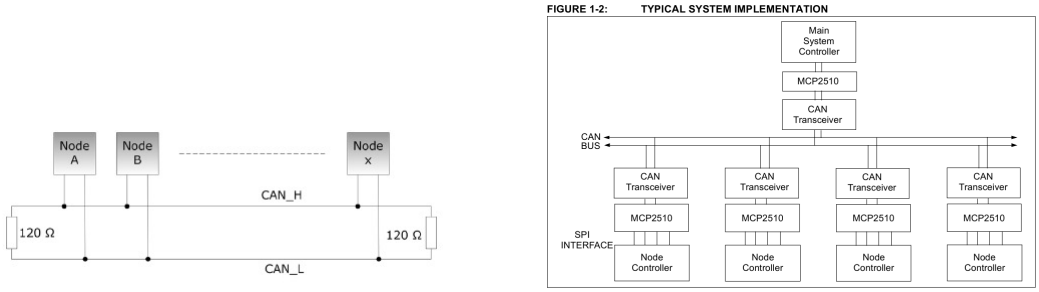

(a) (b)

Abbildung 5.1: CAN Netzwerk; (a): Netzwerk Overview (b): Konkrete Umsetzung mit SPI/CAN Controller

Im autonomen Fahren Projekt kommunizieren die einzelnen Teile (Jetson Nano, Raspberry Pie, Arduino Due und VESC Motor-Controller) ueber CAN. Deshalb ist es letztendlich das Ziel, die Information ueber erkannte Objekte den anderen Teilnehmern — konkret: Raspberry Pie — zu informieren.

Der Jetson Nano besitzt keinen eigenen CAN-Controller. Die Kommunikation muss deshalb ueber Umwegen realisiert werden. Als Baustein fuer die Realisierung SPI nach CAN gibt es extra Zusatzhardware, die zwischen Main Controller (SPI) und CAN-Transceiver zwischengeschalten wird. Beispielhafte Umsetzung mit einem konkreten Baustein *2510* von Microchip ist in Abb. 5.1 (b) zu sehen. Die CAN-Node beinhaltet jetzt den Main Controller (Jetson Nano), SPI-To-CAN Baustein und den CAN-Transceiver.

Die CAN Kommunikation wird ueber den SPI-Controller des Jetson Nano “angestossen”. Die User-Software muss als das Interface des SPI-Controllers verwenden.

Im Linux-Betriebssystem (Jetson Nano: Ubuntu) kann nicht direkt auf die unterliegende Hardware zugegriffen werden. Der Zugriff erfolgt ueber Treibermodule. Diese muessen vor Verwendung geladen werden, wie in Abb. 5.2 dargestellt ist.

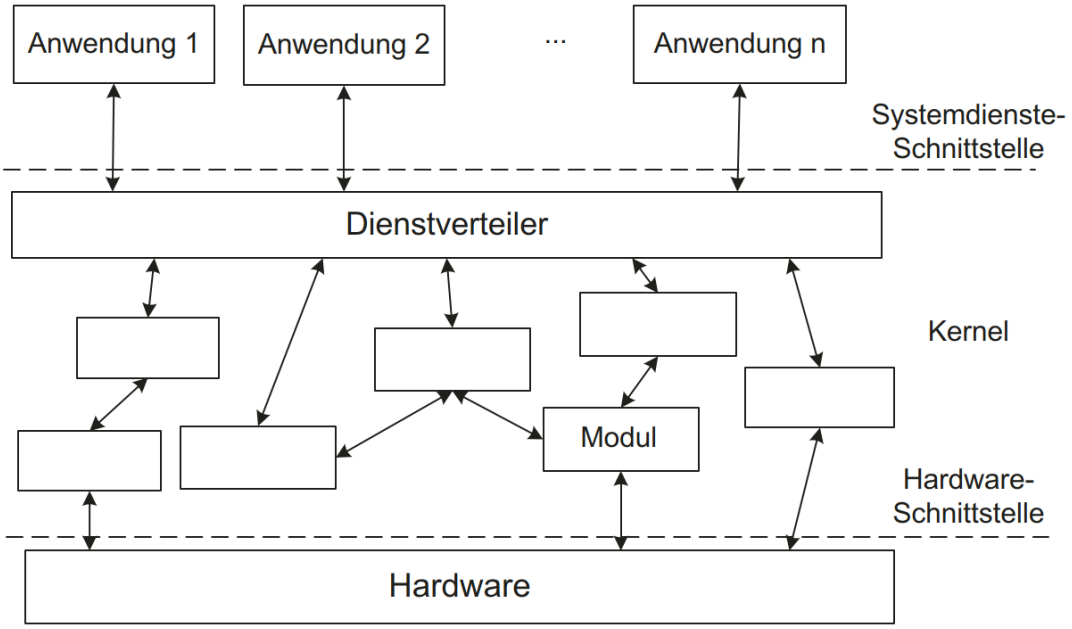

Abbildung 5.2: Hardware Dienstverteiler; Hardwarezugriff erfolgt nur ueber Kernelmodule. Diese muessen davor geladen.

Was anfangs zu pruefen ist, ob schon Module verfuegbar sind, bspw. von NVIDIA, die den Zugriff auf den SPI-Controller bereitstellen.

5.2 Zusammenfassung

Es wurde einen Algorithmus fuer die Objekterkennung in Matlab geschrieben. Der Algorithmus verwendet ein CNN (YoLo-Variante) als Abhaengigkeit. Das CNN uebernimmt die Objekterkennung und wurde von Vorgaengerarbeiten bereitgestellt.

Der Algorithmus wurde als statische CUDA-Library auf dem Zielsystem (Jetson Nano) kompiliert. Die Library wurde dann in einem getrennten Programm als Abhaengigkeit eingebunden. Diese Vorangehensweise, Matlab Algorithmus als statische Library zu kompilieren und im Zielsystem als statische Abhaengigkeit einzubinden, bietet den Vroteil:

- Aenderungen im Objekterkennungsprozess sind unabhaengig vom Host-PC
  - Auf Host-PC wurde der Algorithmus in der Matlab-IDE erstellt
  - Somit entfallen langwierige Uebertragungs- und Kompilierungsprozesse, -/zeiten
    - Uebertragung von Matlab-Code muss via LAN uebertragen werden
    - Starten von “geschlossenen” Matlabalgorithmen werden von der Matlab-IDE im Host-PC “angestossen”
- Das Starten von Algorithmen kann automatisch ueber ein Skript “angestossen” werden

Es wurde eine Verarbeitungspipeline vorgestellt. Der Objekterkennungsprozess ermittelt Objekte in den Liveaufnahmen. Weitere “Filterungen” werden in anderen, getrennten Prozessen durchgefuehrt. Bspw. wurde eine Idee vorgestellt, nicht fuer jeden aufgenommenen Frame immer das selbe erkannte Objekt zu uebertragen, dass nur unter bestimmten Bedingungen neue Nachrichten fuer das selbe Objekt uebertragen werden.

Es wurde weiter ausgefuehrt, dass andere Algorithmen die Pipeline einfach erweitern, oder andere entfehrnt werden koennen. Der letzte Prozess der Verarbeitungspipeline ist fuer die Versendung der entguehltigen Nachrichten vorgesehen. Allgemein koennen weitere Prozesse der Pipeline in beliebigen Sprachen geschrieben werden. So kann auch der letzte Prozess, der die Nachricht schlussendlich ueber CAN versendet, bspw. in Python geschrieben werden. Von NVIDIA sind zahlreiche Skripte und Libraries in Python bereitgestellt.

Zuletzt ist erlaeutert worden, wie die CAN Kommunikation konkret in Hardware umgesetzt werden kann.

5.3 Ausblick

- Unterliegendes CNN von binaere Erkennung von Klassen auf Erkennung mehrerer Klassen — nicht nur Klasse von Auto auf bspw. Auto, LKW, Fahrrad, Fussgaenger, ...
- Untersuchung Kuehlsystem auf Systemstabilitaet
- Umsetzung CAN Kommunikation

Literaturverzeichnis

[bgu] BGULLA:
Jetson Nano Cheat-Sheet.
http://gist.github.com/bgulla/5d7afdb6575e8ef0260b7ab0507b014b, . –
Last Accessed: 2021-04-27

[Bos20] BOSL, A.:
Einführung in MATLAB/Simulink: Berechnung, Programmierung, Simulation.
Carl Hanser Verlag GmbH & Company KG, 2020 https://books.google.de/books?id=SVoAEAAAQBAJ. –
ISBN 9783446465466

[BS20] BRIEM, Stefan ; STROHMAIER, Lukas:
Objekterkennung mit KNN, Hochschule Aalen, Diplomarbeit, 2020

[Nvi01a] NVIDIA:
JETSON NANO.
http://www.nvidia.com/de-de/autonomous-machines/embedded-systems/jetson-nano/education-projects/, 2020-09-01. –
Last Accessed: 2021-04-14

[Nvi01b] NVIDIA:
JETSON NANO - Getting Started.
http://developer.nvidia.com/embedded/learn/get-started-jetson-nano-devkit, 2020-09-01. –
Last Accessed: 2021-04-14